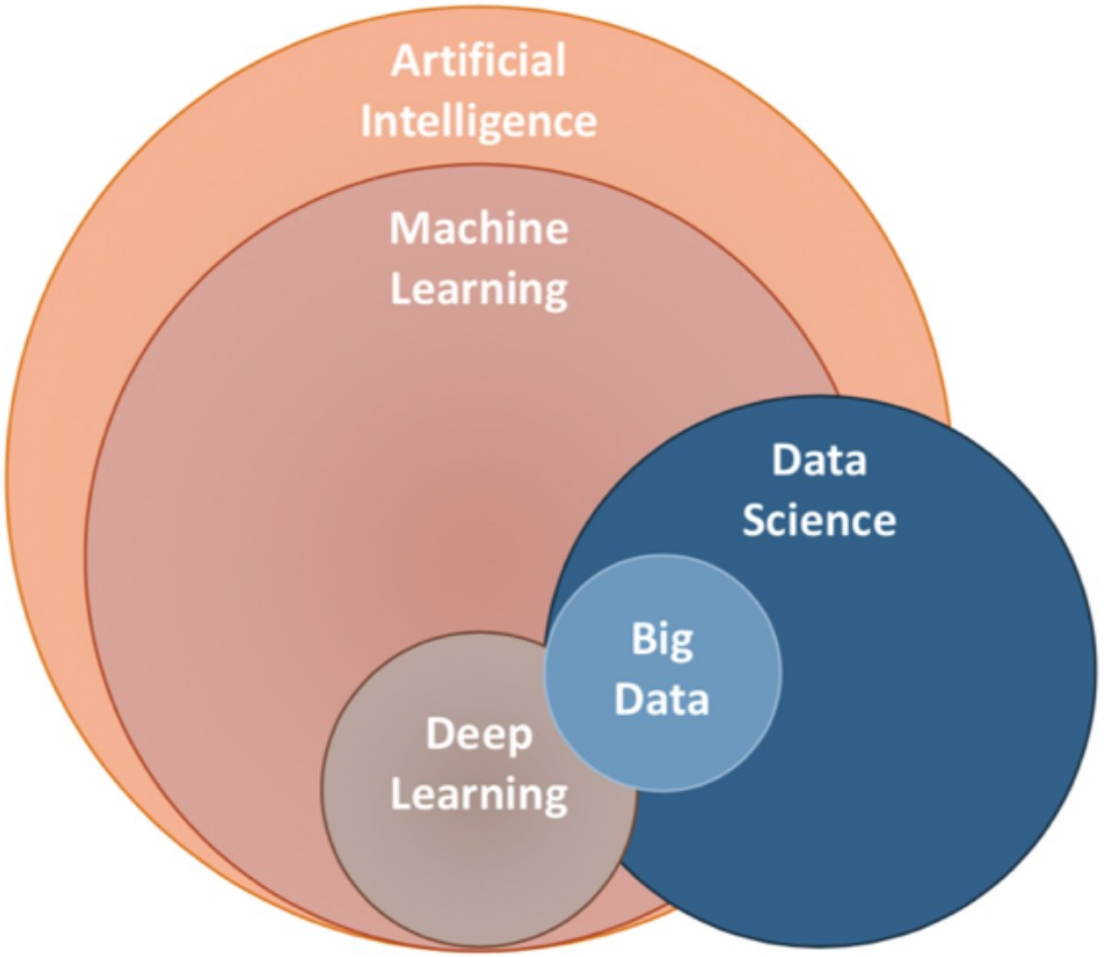

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGÓN

Definición: El big data está formado por conjuntos de datos de mayor tamaño y más complejos, especialmente procedentes de nuevas fuentes de datos. Estos conjuntos de datos son tan voluminosos que el software de procesamiento de datos convencional sencillamente no puede gestionarlos. Sin embargo, estos volúmenes masivos de datos pueden utilizarse para abordar problemas empresariales que antes no hubiera sido posible solucionar.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

TECH FAB LAB

IAF Instituto Aragonés de Fomento

FUENTES DE DATOS

Una fuente de datos es un conjunto de datos estadísticos, estudios de organismos públicos, informes y asociaciones que conforman un agrupamiento muy valioso para las organizaciones

Web y Redes Sociales

Clicks en vínculos
Búsquedas en Google
RRSS (Facebook, Twitter)
Contenido Web (páginas, imágenes)

Entre máquinas

RFID
GPS
Otros sensores

Personas

Grabaciones de llamadas
E-mail
Registros médicos

Transacciones

Llamadas
Mensajería
Facturación (pagos con tarjeta y online)

Biométricos

Reconocimiento facial
Reconocimiento iris
ADN

Financiado por la Unión Europea
NextGenerationEU

GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA

Plan de Recuperación, Transformación y Resiliencia

GOBIERNO DE ARAGON

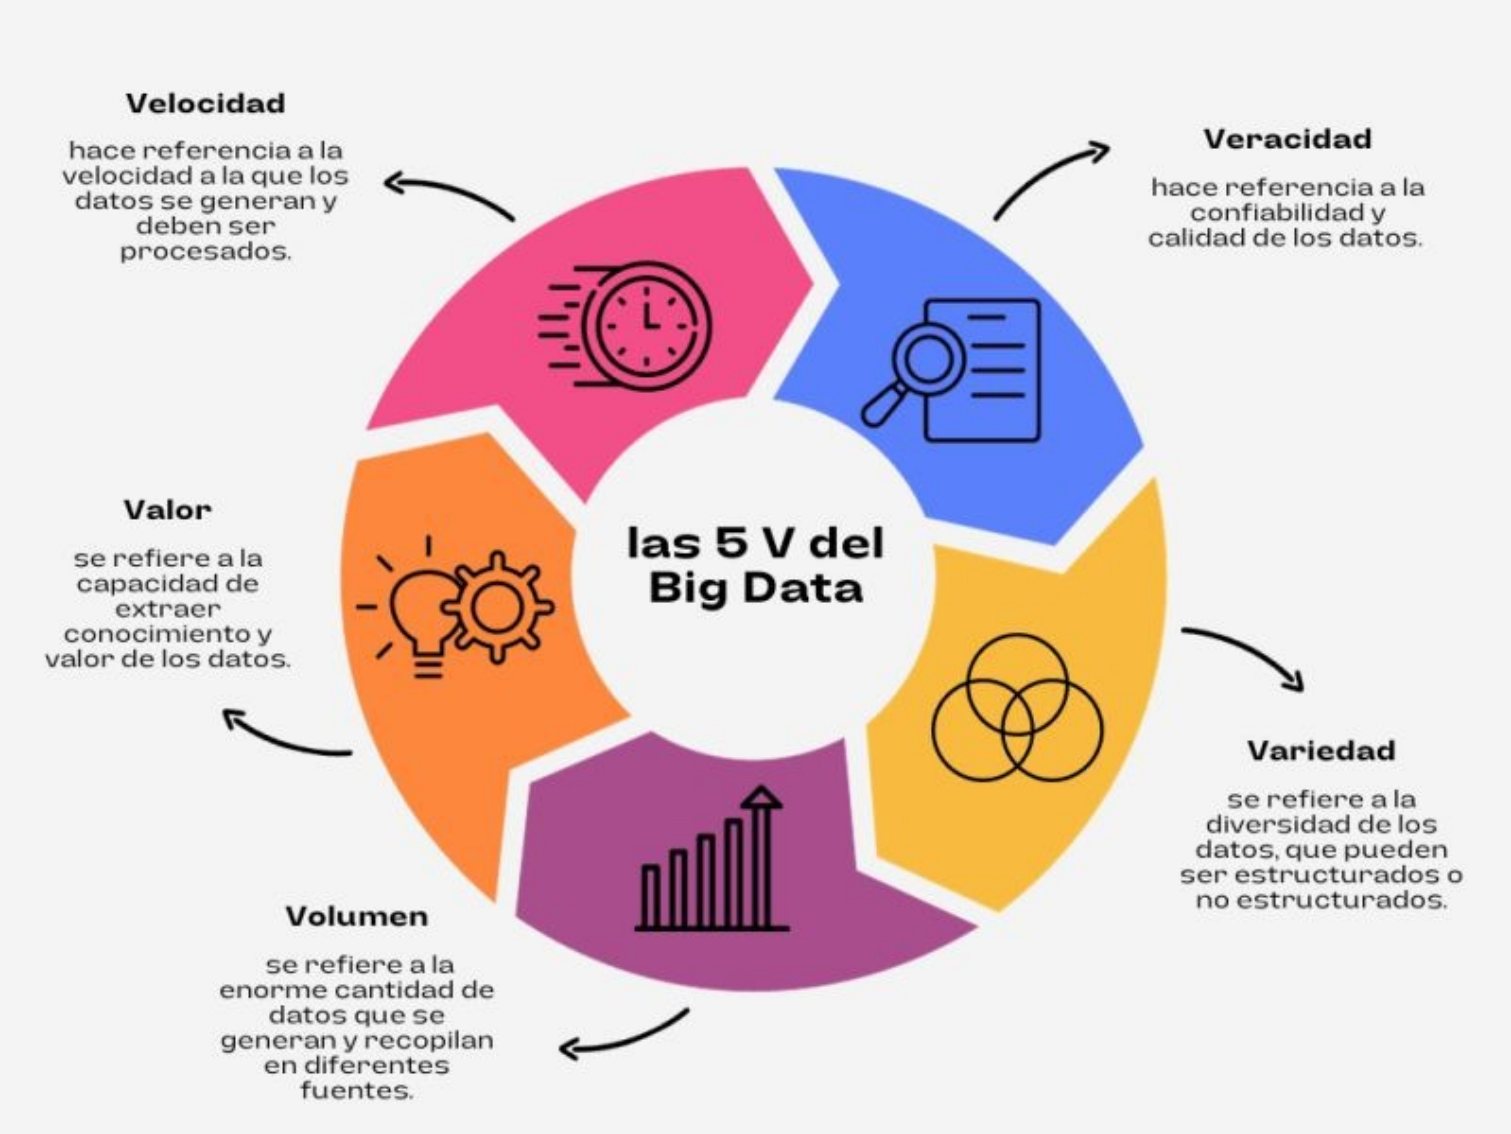

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Las 7 V´S DEL BIG DATA

VOLUMEN
Cantidad de datos que son generados y se almacenan con la finalidad de ser procesados.

VARIEDAD
Variedad de formas, tipos y fuentes de registro de datos: estructurados y no estructurados.

VELOCIDAD
Rapidez en la que los datos son creados.

VIABILIDAD
Uso eficaz de la totalidad de datos.

VERACIDAD
Grado de fiabilidad de la información.

VALOR
La transformación de los datos en información, se convierte en conocimiento para la toma de desiciones.

VISUALIZACIÓN
Representación visual de los datos para que sean legibles y accesibles. Facilita encontrar patrones en el tema a investigar.

TECH FAB LAB
IAF Instituto Aragonés de Fomento
Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGÓN

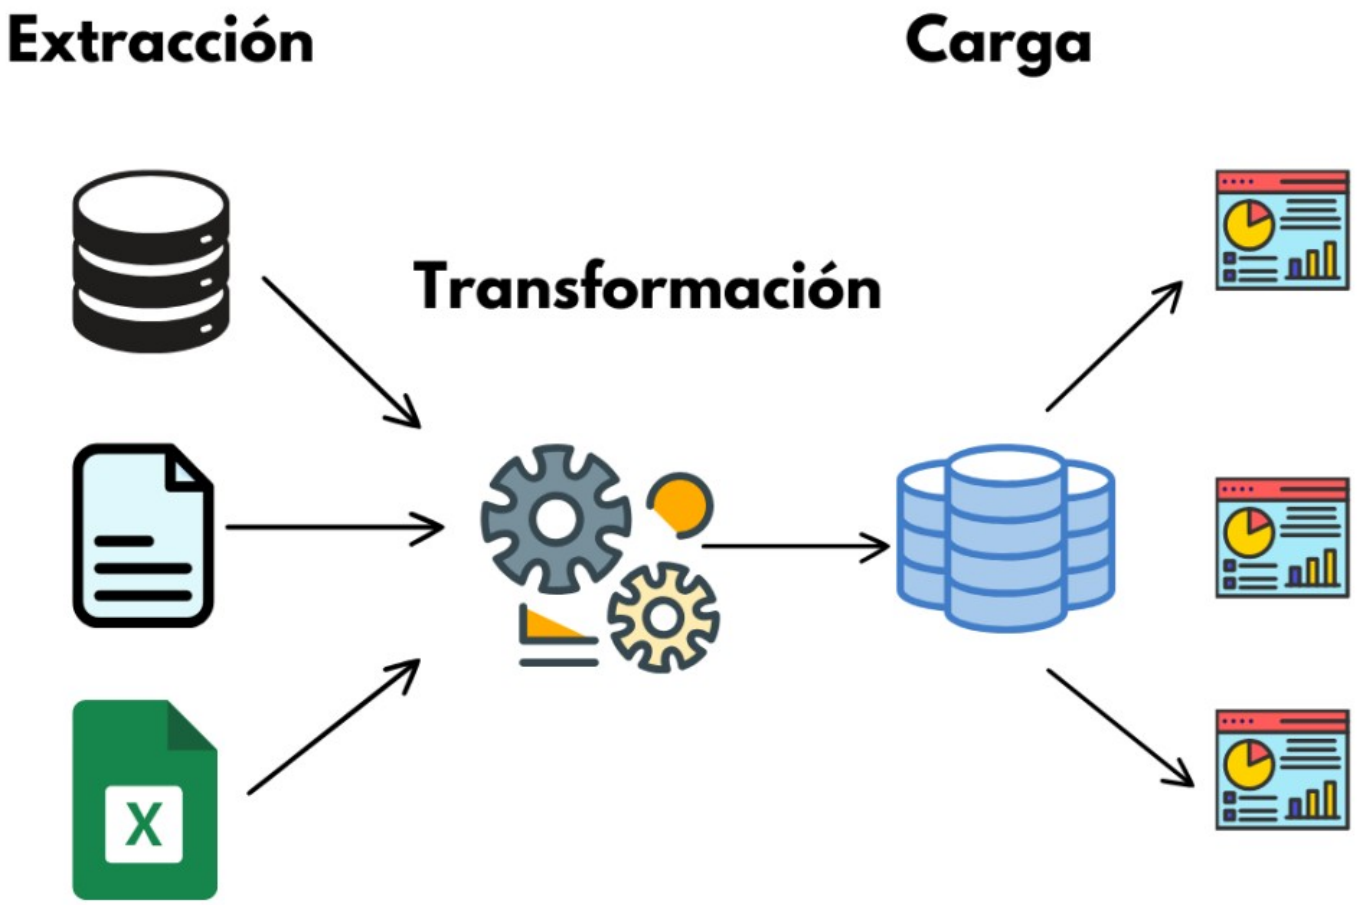

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Definición de ETL

ETL es un proceso que convierte datos crudos en información útil para la toma de decisiones. Se divide en tres fases fundamentales:

1. **Extracción (Extract):** Se obtienen datos de diversas fuentes, como bases de datos, archivos CSV, APIs, aplicaciones empresariales y más.
2. **Transformación (Transform):** Los datos extraídos se procesan, limpian y adaptan a un formato óptimo para su análisis.
3. **Carga (Load):** Los datos transformados se almacenan en un destino final, como un data warehouse o un lago de datos.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

TECH FAB LAB

IAF Instituto Aragonés de Fomento

Financiado por la Unión Europea
NextGenerationEU

GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA

Plan de Recuperación, Transformación y Resiliencia

GOBIERNO DE ARAGON

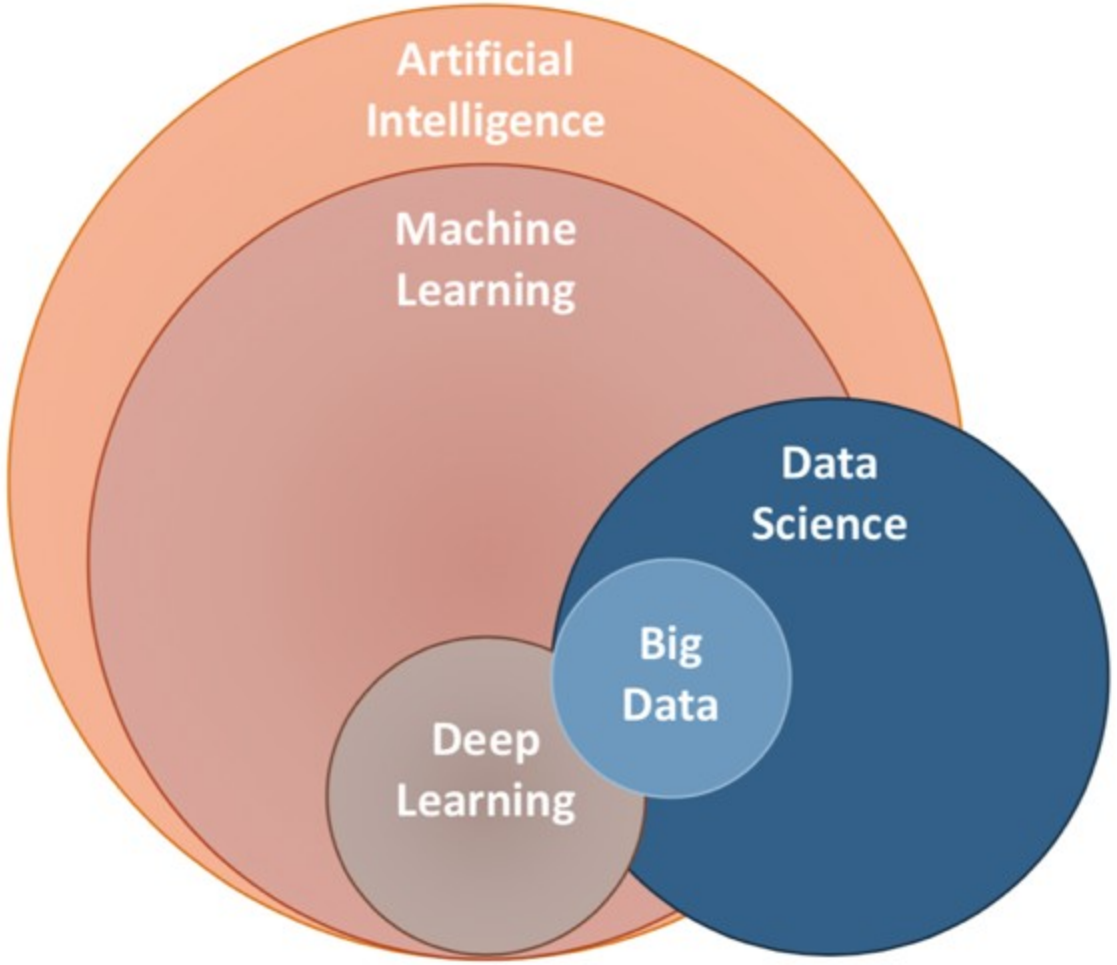

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

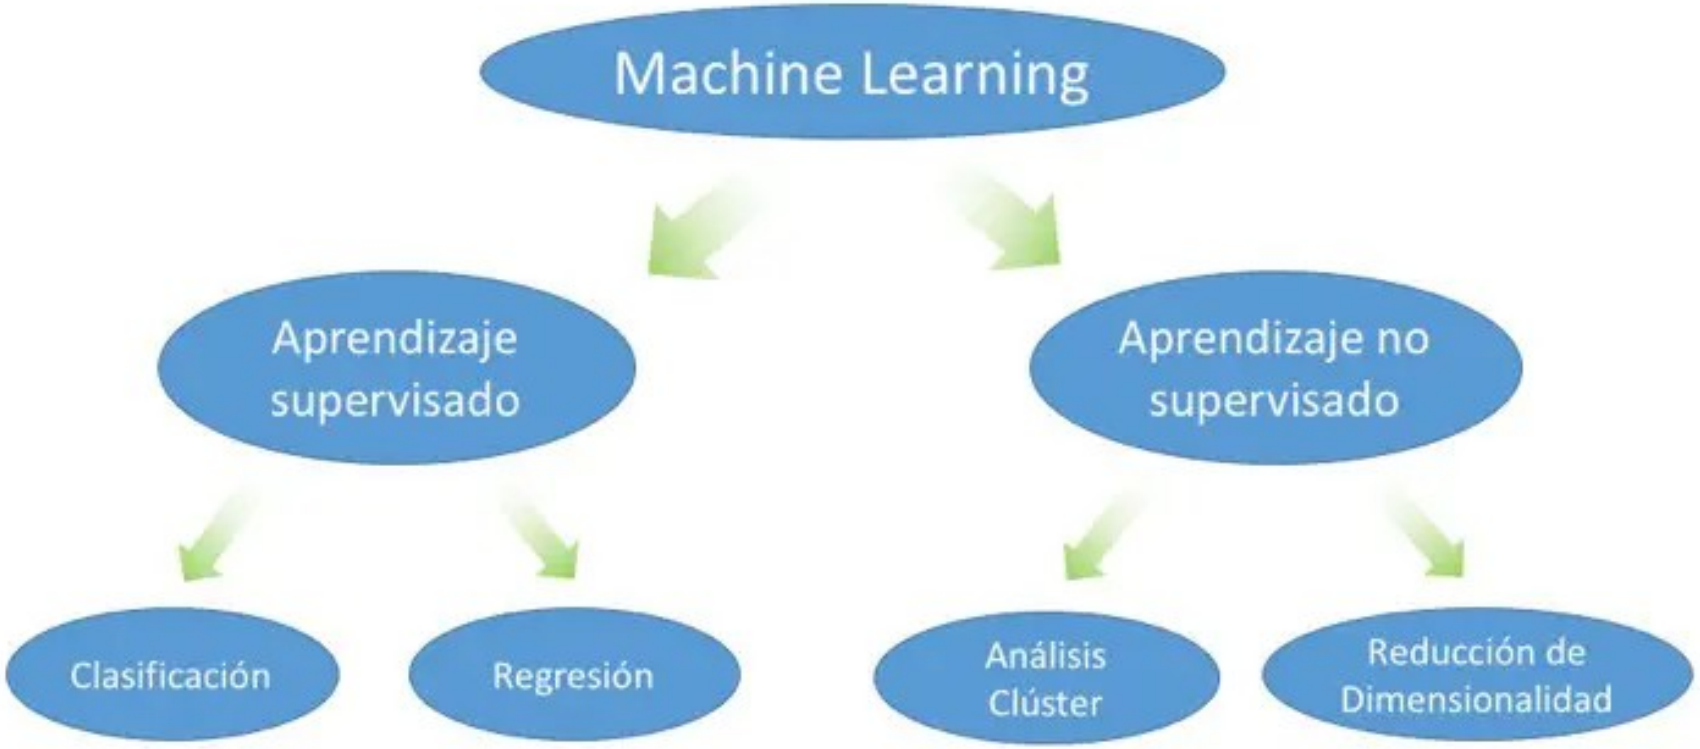

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Machine Learning (aprendizaje automático): es una rama de la inteligencia artificial que permite que las computadoras aprendan y mejoren sus tareas de forma autónoma a partir de datos, sin necesidad de que alguien las programe específicamente para cada acción

¿Cómo funciona?

1. **Recolección de datos**: Se reúnen ejemplos (imágenes, textos, números).
2. **Entrenamiento**: Un algoritmo procesa estos datos para crear un **modelo**.
3. **Predicción**: El modelo usa lo aprendido para dar respuestas sobre datos nuevos que nunca ha visto.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Supervisado: se entrena con etiquetas, es decir, pares entrada–salida (ej. imágenes etiquetadas con la categoría “perro/gato”).

No supervisado: se entrena únicamente con los datos de entrada, sin etiquetas (ej. imágenes sin categorías previas, el modelo debe encontrar similitudes por sí mismo).

Mientras que el aprendizaje supervisado se centra en la *predicción*, el no supervisado se centra en la *exploración y descubrimiento*.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Apredizaje supervisado

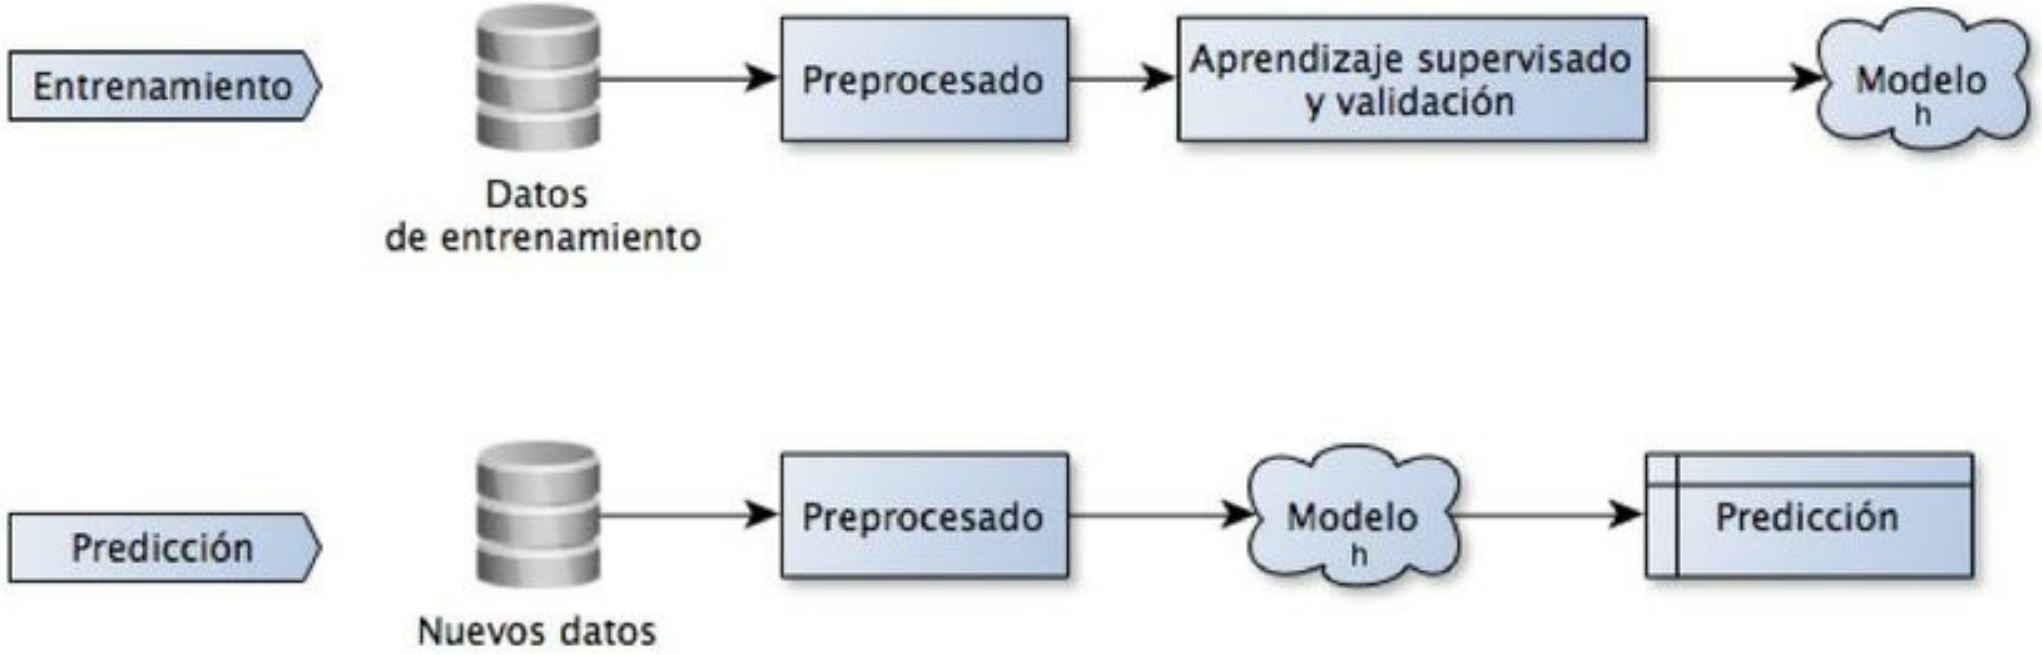

Financiado por
la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Apredizaje supervisado

- **Características clave**

Necesidad de etiquetas: se requiere un dataset previamente anotado.

Métrica: guía el aprendizaje, mide el error entre predicciones y realidad.

Capacidad de generalización: el éxito del modelo no depende de memorizar los datos, sino de su capacidad de funcionar en ejemplos nuevos.

Equilibrio entre sesgo y varianza: los modelos deben encontrar un punto óptimo entre simplicidad y complejidad para evitar tanto el *underfitting* como el *overfitting*.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Separación de los datos: Entrenamiento y Test

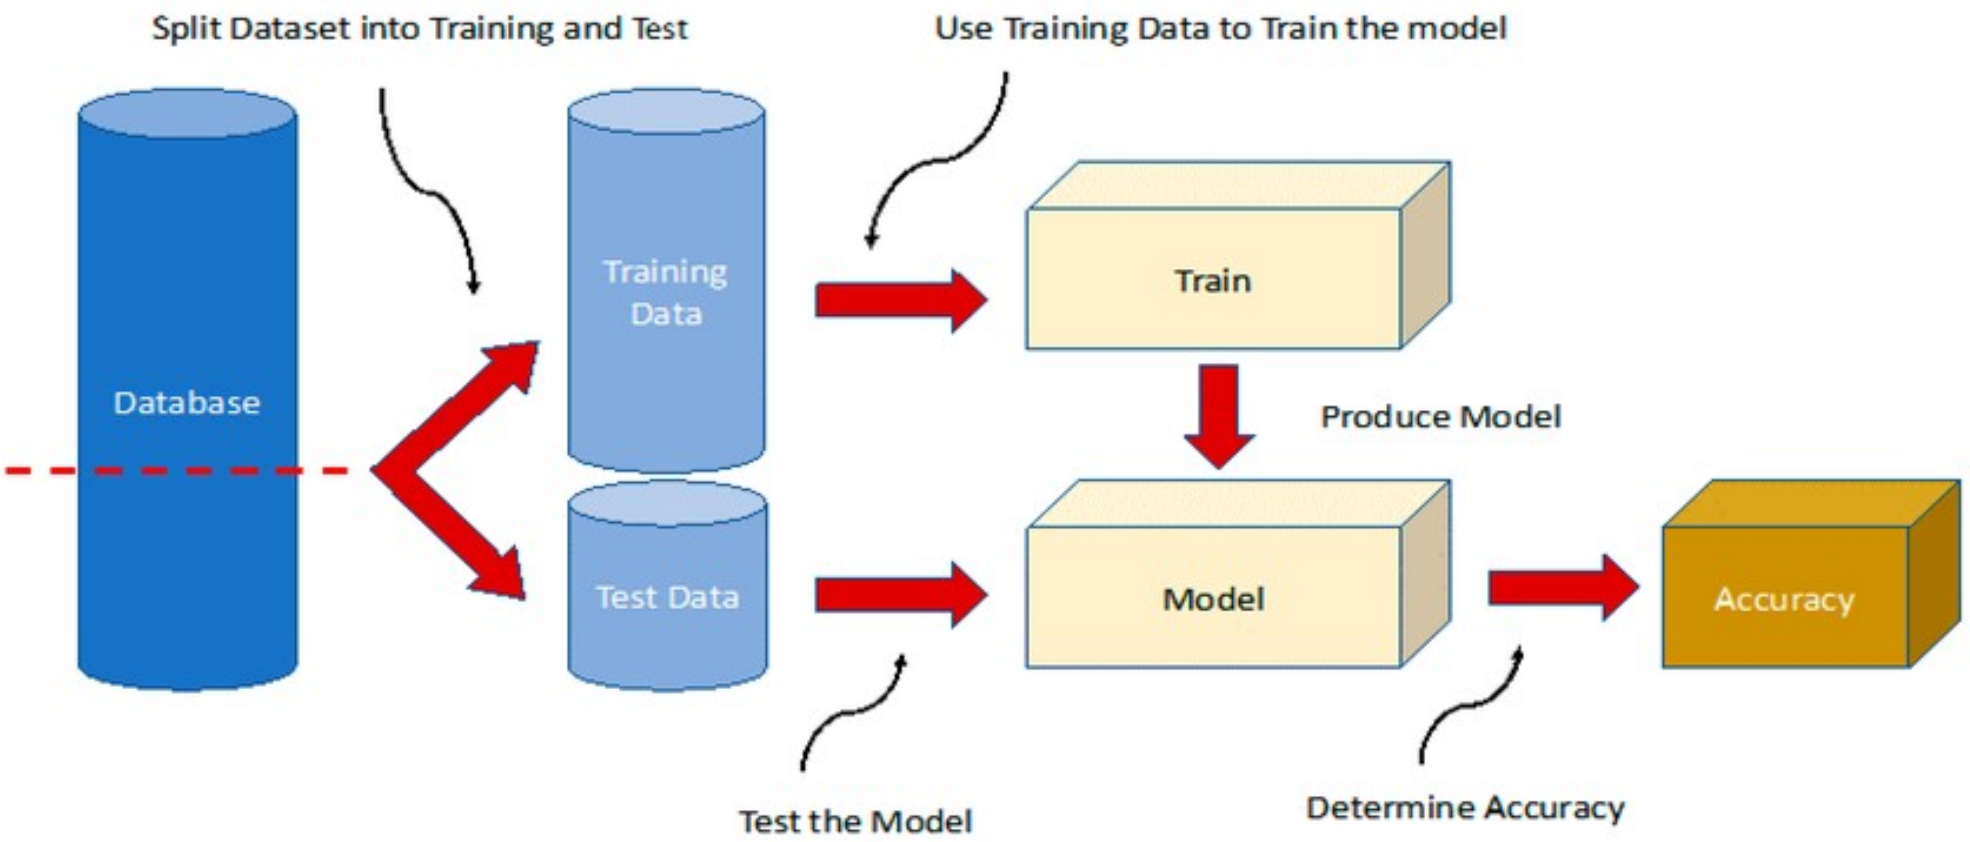

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Separación de los datos: Entrenamiento y Test

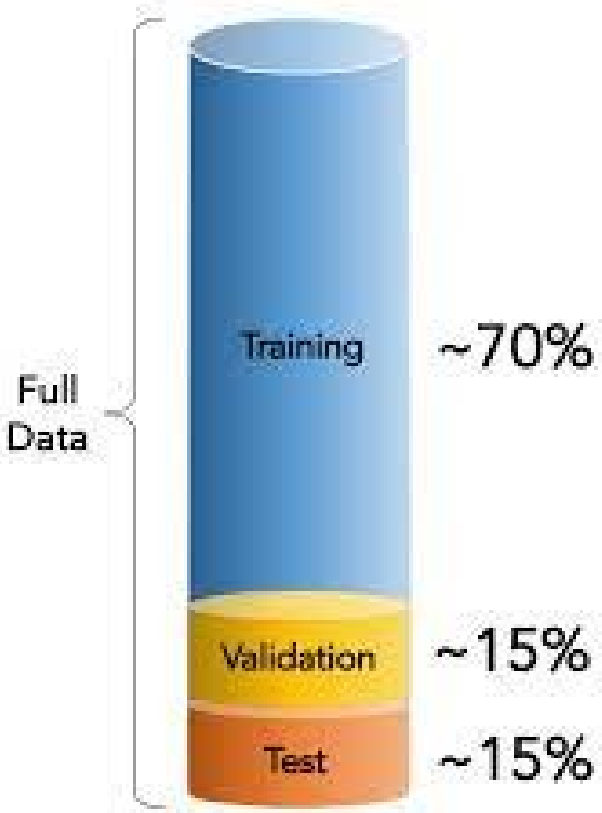

- **Conjunto de Entrenamiento (Train Set)**
  - Propósito: Aprender.
  - Esta es la mayor parte de los datos. El modelo utiliza este conjunto para analizar los patrones, encontrar relaciones y construir su lógica interna. Aquí es donde ocurre el model.fit().

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Separación de los datos: Entrenamiento y Test

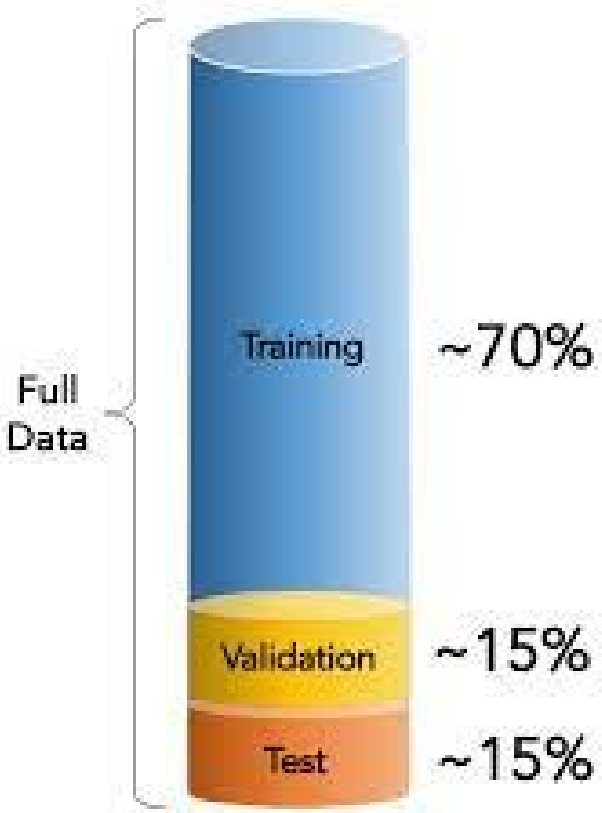

- **Conjunto de Validación (Validation Set)**
  - Propósito: Ajustar (Tuning).
  - El modelo usa este conjunto para tomar decisiones de configuración (llamadas hiperparámetros).
  - El modelo se evalúa repetidamente contra este set para encontrar la configuración óptima sin tocar el conjunto de prueba final.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Separación de los datos: Entrenamiento y Test

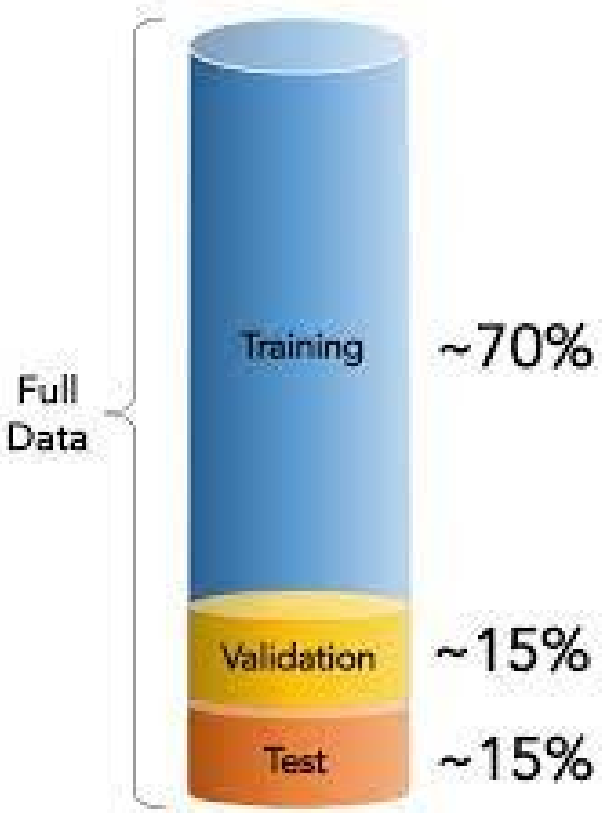

- **Conjunto de Prueba (Test Set)**
  - Propósito: Evaluar.
  - Este conjunto se mantiene totalmente separado y se usa una sola vez al final, cuando el modelo ya está entrenado y ajustado.
  - Proporciona la métrica final y honesta de cómo el modelo generalizará a datos nuevos que nunca ha visto.

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Validación cruzada

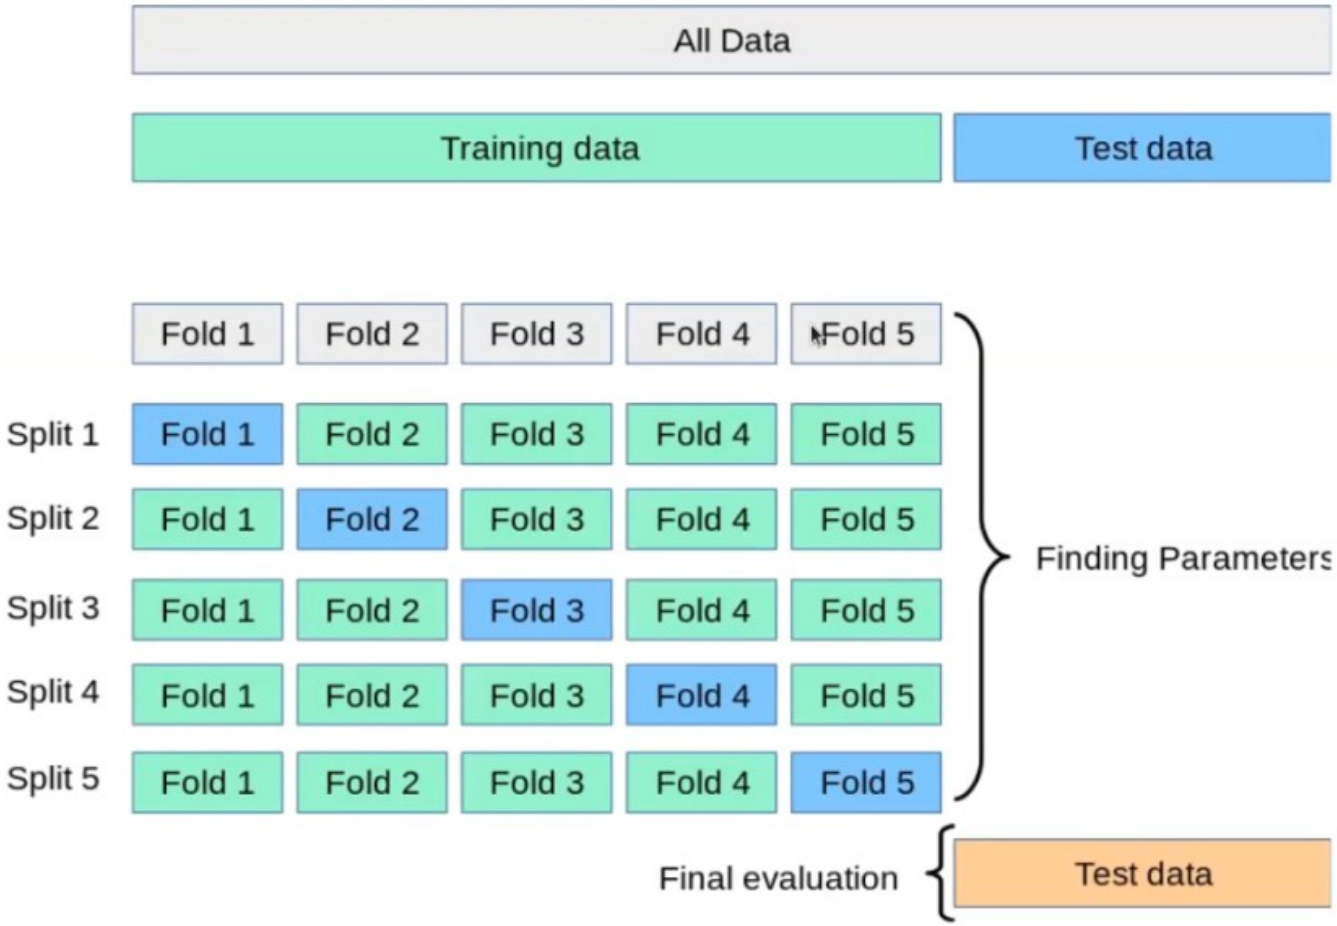

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

- **Ventajas**
  - **Evaluación Robusta**: Al promediar los resultados de las (k) iteraciones, se obtiene una métrica de rendimiento general que es menos sensible a la división aleatoria específica de los datos.
  - **Mitiga el Sobreajuste (Overfitting):** Ayuda a asegurar que el modelo no se ha ajustado demasiado a un subconjunto particular de datos, proporcionando una mejor idea de cómo se desempeñará en datos realmente nuevos.
  - **Uso Eficiente de los Datos:** Permite utilizar todo el conjunto de datos tanto para entrenar como para validar el modelo, lo cual es crucial cuando se dispone de una muestra limitada
  - **Permite la Comparación de Modelos**: Facilita una comparación justa y objetiva entre diferentes algoritmos o configuraciones de modelos, ya que todos se evalúan sobre las mismas divisiones de datos subyacentes

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

- **Desventajas**
  - **Alto Costo Computacional:** La desventaja más significativa. Si se utiliza k=10, el modelo debe ser entrenado y evaluado diez veces en lugar de solo una. Esto puede ser prohibitivo para modelos complejos o conjuntos de datos muy grandes.
  - **Mayor Tiempo de Ejecución:** Consecuencia directa del punto anterior, el tiempo total para completar el proceso de evaluación es significativamente mayor.
  - **Cuidado en Datos Secuenciales:** Si los datos tienen una dependencia temporal (series temporales), una división aleatoria simple no es adecuada, ya que mezclaría el futuro con el pasado

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Hiperparámetros

- **Definición:** son variables de configuración externas que se establecen manualmente antes de que comience el proceso de entrenamiento de un modelo de machine learning. A diferencia de los parámetros del modelo (que se aprenden automáticamente a partir de los datos durante el entrenamiento), los hiperparámetros controlan la arquitectura y el comportamiento del algoritmo de aprendizaje

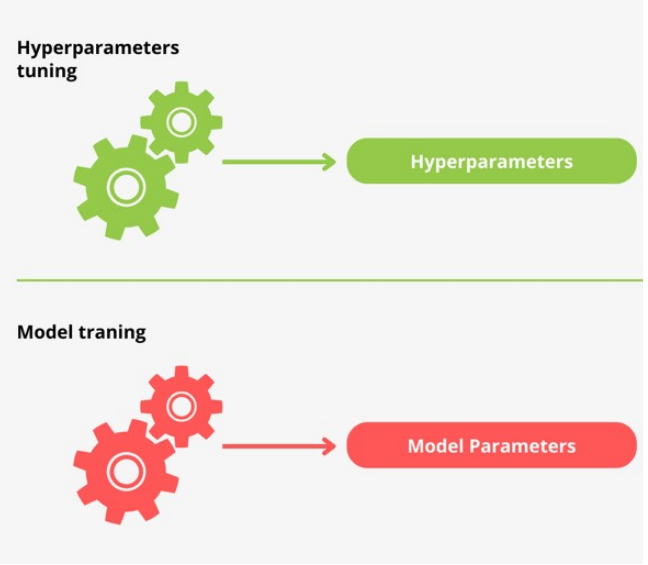

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

- **Optimización de hiperparámetros:**
  - Consiste en buscar la mejor combinación de estos valores para mejorar el rendimiento del modelo
  - influyen directamente en la capacidad del modelo para aprender patrones complejos. Una configuración inadecuada puede llevar a un modelo que no aprende lo suficiente (subajuste) o a uno que memoriza los datos de entrenamiento (sobreajuste)
  - La optimización permite adaptar el algoritmo a las características específicas de los datos y los requisitos de la tarea
  - La elección de hiperparámetros puede afectar significativamente la velocidad a la que se entrena un modelo

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

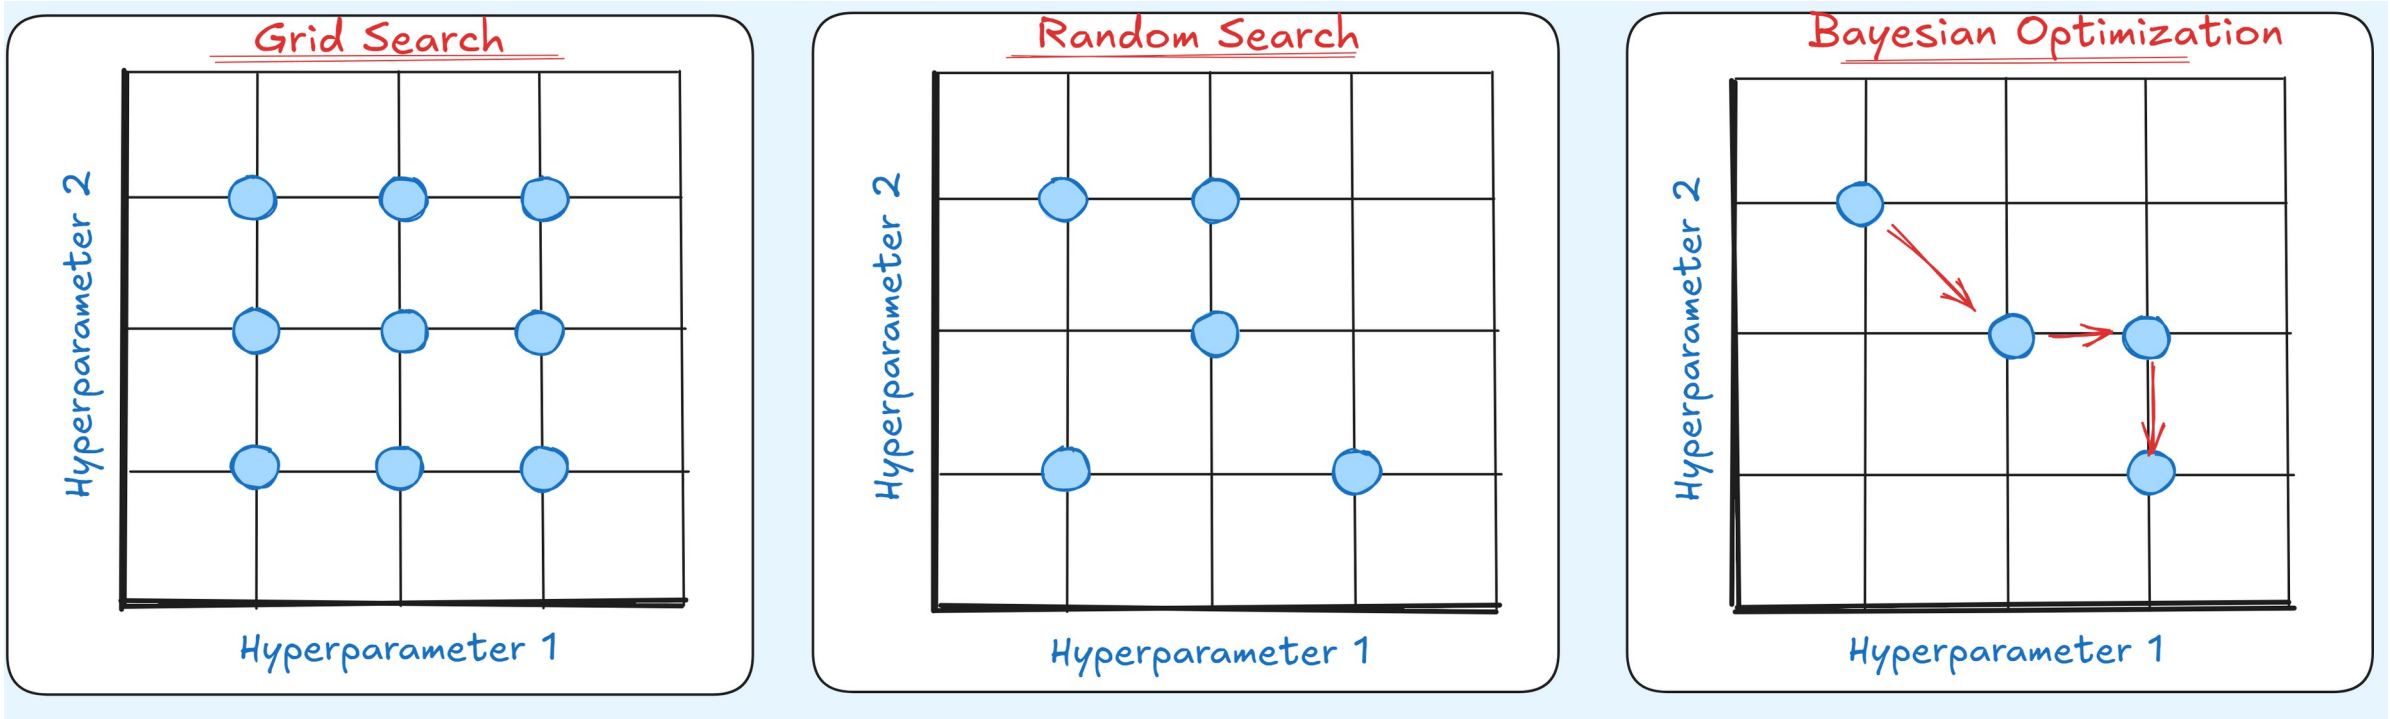

TECH FAB LAB
IAF Instituto Aragonés de Fomento
Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

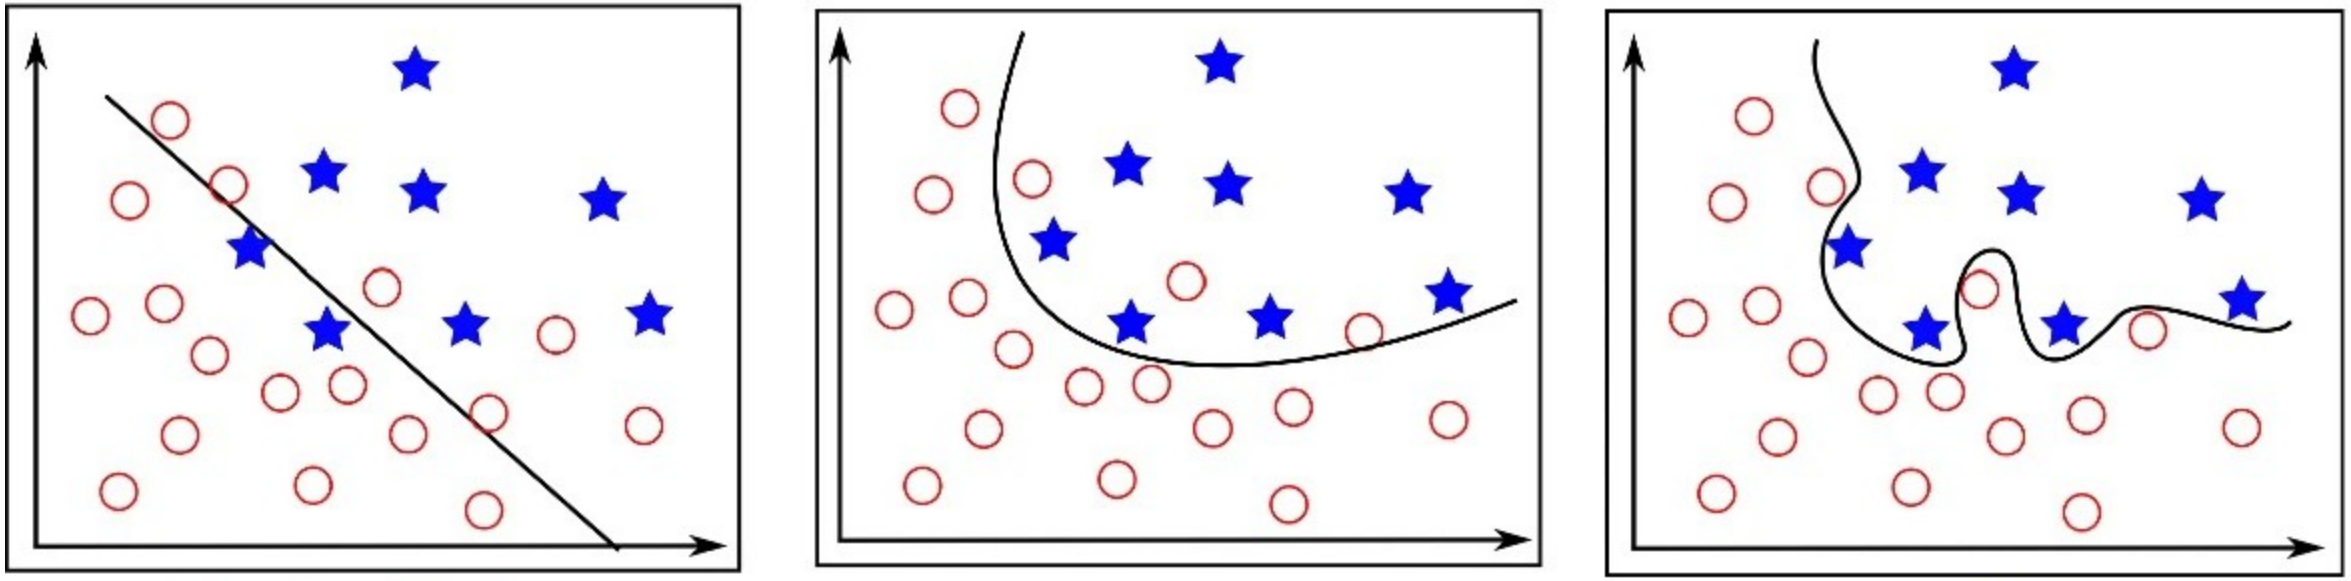

Underfitting

Overfitting

Financiado por la Unión Europea NextGenerationEU

GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA

Plan de Recuperación, Transformación y Resiliencia

GOBIERNO DE ARAGON

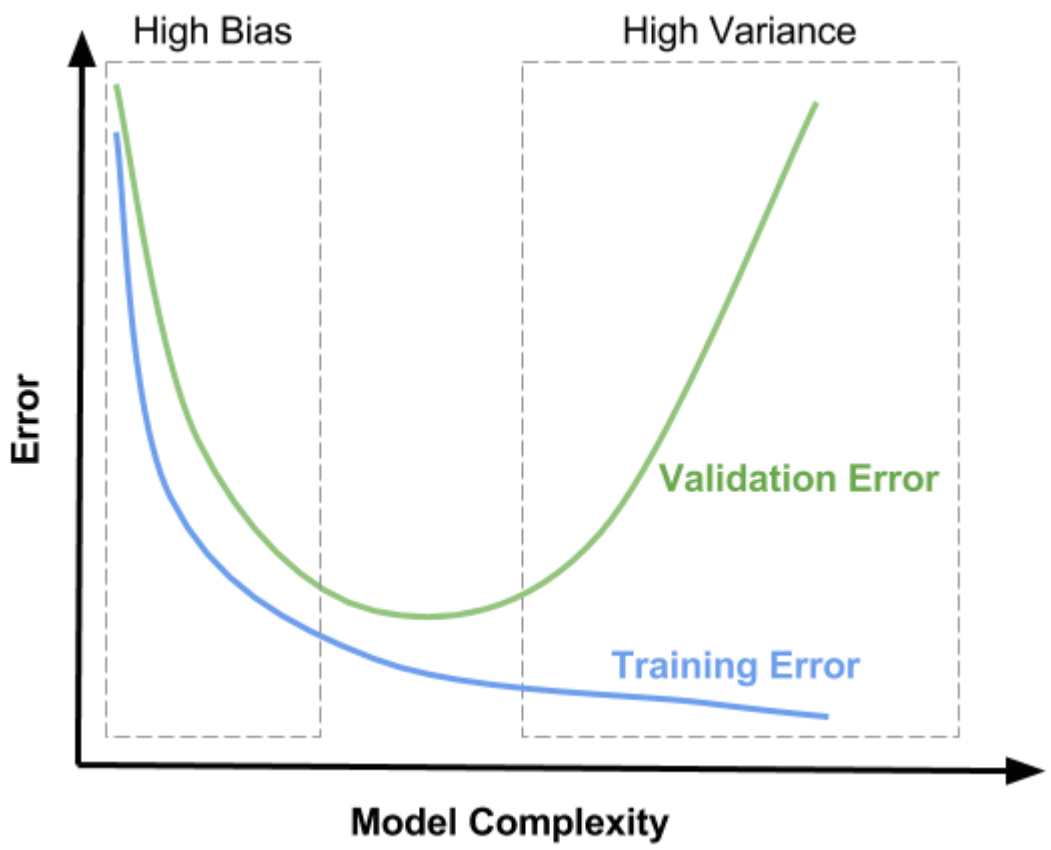

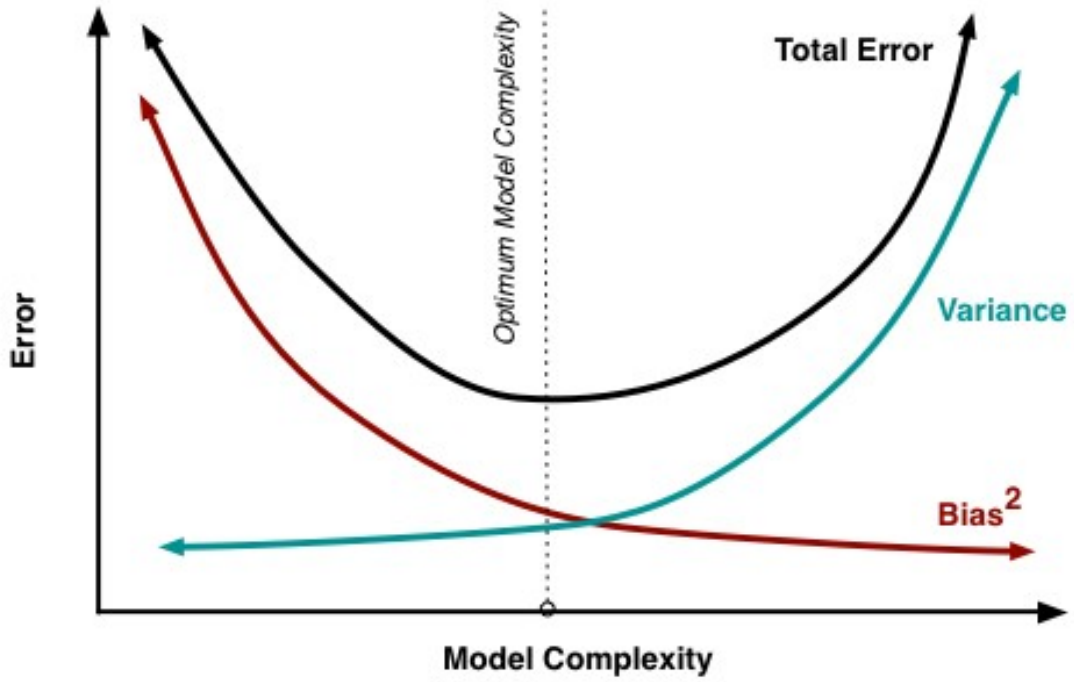

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Métricas

- **Definición:** es una medida cuantitativa utilizada para evaluar el rendimiento, la eficacia y la calidad de un modelo de aprendizaje automático
  - **Evaluación objetiva:** Permiten saber qué tan bien se comporta un modelo al realizar predicciones con datos no vistos anteriormente.
  - **Toma de decisiones:** Guían la elección del mejor modelo para un problema específico y ayudan a identificar si es adecuado para su implementación en un entorno real.
  - **Identificación de problemas:** Ayudan a diagnosticar si un modelo tiene problemas como el sobreajuste (overfitting) o subajuste (underfitting).
  - **Comunicación de resultados:** Facilitan la comunicación del desempeño del modelo a las partes interesadas, como clientes o equipos de negocio

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Métricas de Regresión

- **Error Cuadrático Medio (MSE):** El promedio de las diferencias al cuadrado entre los valores predichos y los valores reales, penalizando más los errores grandes

  - Penaliza más los errores grandes por el cuadrado.
  - Útil para optimización, ya que es diferenciable.
  - Desventaja: menos interpretable directamente.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

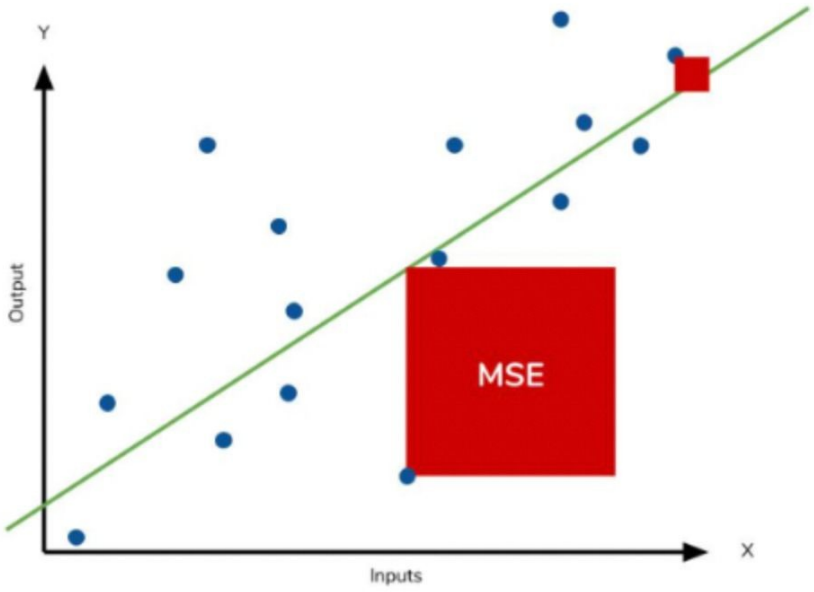

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

- **Coeficiente de Determinación (R^2):** Representa la proporción de variabilidad explicada por el modelo.

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

$$R^2 = 1 - \frac{\text{Varianza no explicada (Error del modelo)}}{\text{Varianza total (Error del modelo base)}}$$

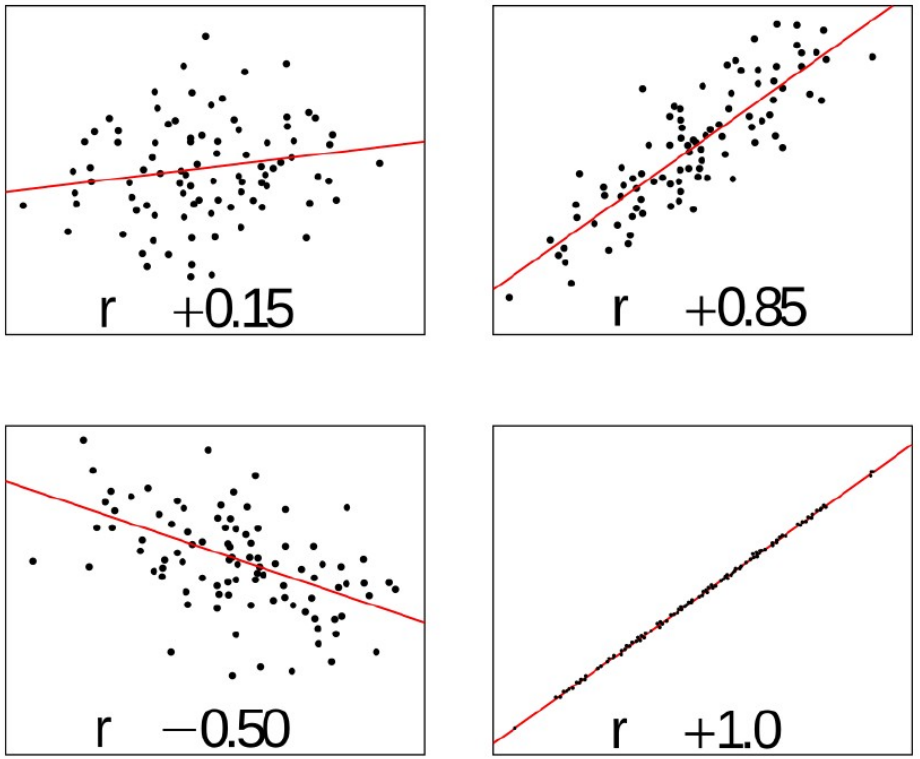

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Métricas de Clasificación

- Matriz de confusión: Es una tabla que compara las clases reales (verdaderas) de los datos con las clases predichas por el modelo. Permite análisis detallado de los errores del modelo y es la base para calcular todas las métricas de rendimiento

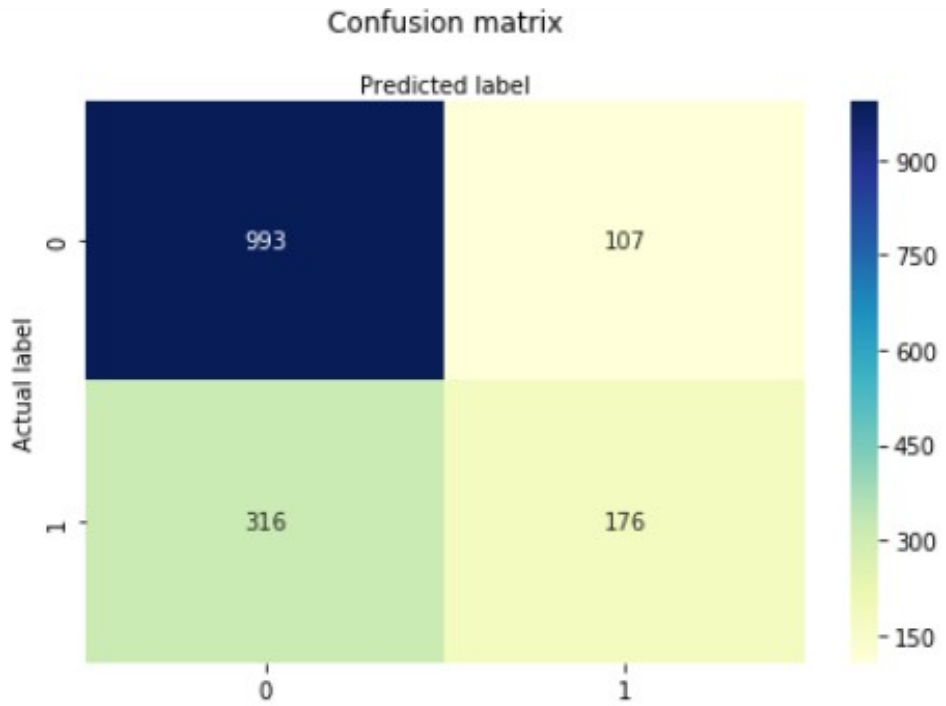

Financiado por la Unión Europea
NextGenerationEU
GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Métricas de Clasificación

Predicted Class	Actual Class
No Cancer	No Cancer
Has Cancer	Has Cancer
No Cancer	No Cancer
No Cancer	No Cancer
No Cancer	Has Cancer
Has Cancer	Has Cancer
No Cancer	No Cancer
Has Cancer	No Cancer
No Cancer	No Cancer
No Cancer	No Cancer
Has Cancer	No Cancer
No Cancer	No Cancer

Predicted Class \ Actual Class	Has Cancer	No Cancer
Has Cancer	2	2
No Cancer	1	7

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Métricas de Clasificación

$$\text{Accuracy} = \frac{\blacksquare + \blacksquare}{\blacksquare + \blacksquare + \blacksquare + \blacksquare}$$

$$\text{Precisión Clase 1} = \frac{\blacksquare}{\blacksquare + \blacksquare}$$

$$\text{Recall Clase 1} = \frac{\blacksquare}{\blacksquare + \blacksquare}$$

$$\text{Precisión Clase 2} = \frac{\blacksquare}{\blacksquare + \blacksquare}$$

$$\text{Recall Clase 2} = \frac{\blacksquare}{\blacksquare + \blacksquare}$$

	Predicción Clase 1	Predicción Clase 2
Valor real Clase 1	Aciertos True Positive Clase 1	Fallos False Positive Clase 2
Valor real Clase 2	Fallos False Positive Clase 1	Aciertos True Positive Clase 2

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGON

Métricas de Clasificación

- **F1 Score:** es una métrica crucial que ofrece un equilibrio entre dos medidas que a menudo compiten entre sí: la Precisión y Recall

  - Útil para evaluar modelos de clasificación en conjuntos de datos con un desequilibrio de clases, donde una clase es mucho más común que la otra.

  - La media armónica penaliza los valores extremos. Esto significa que el F1-score solo será alto si tanto la precisión como el recall son altos

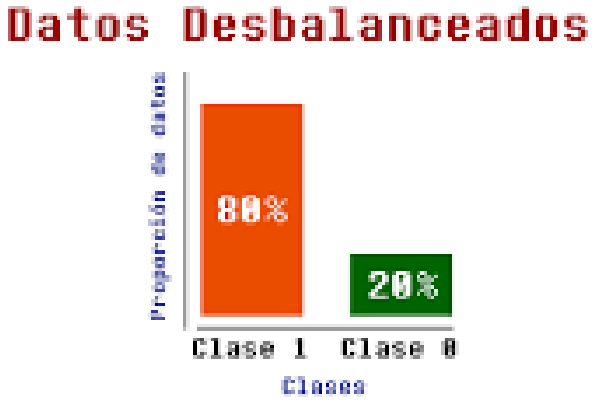

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

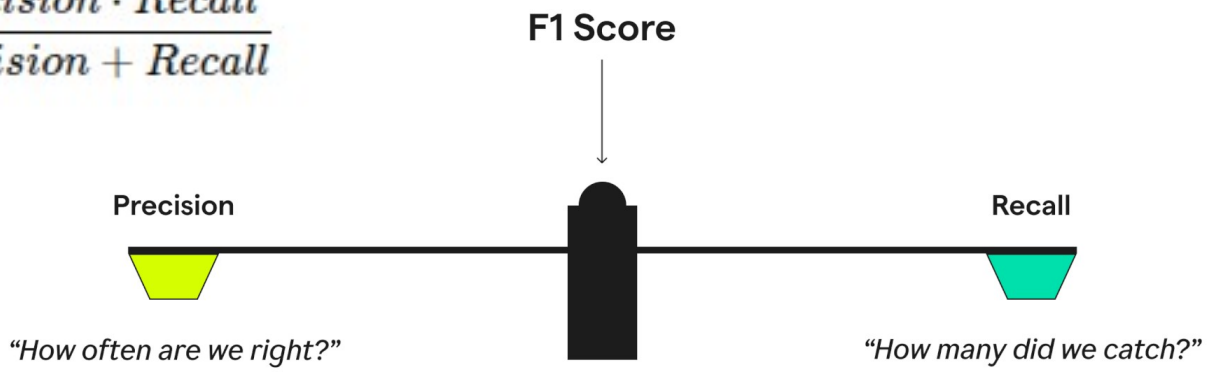

Financiado por la Unión Europea NextGenerationEU
GOBIERNO DE ESPAÑA MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA
Plan de Recuperación, Transformación y Resiliencia
GOBIERNO DE ARAGÓN

TECH FAB LAB

IAF Instituto Aragonés de Fomento

Financiado por la Unión Europea
NextGenerationEU

GOBIERNO DE ESPAÑA
MINISTERIO PARA LA TRANSFORMACIÓN DIGITAL Y DE LA FUNCIÓN PÚBLICA

Plan de Recuperación, Transformación y Resiliencia

GOBIERNO DE ARAGÓN