Módulo de Trabajo: Casos Prácticos en el Sector Salud

Construyendo Asistentes Médicos Locales con **Docker Model Runner** (DMR)

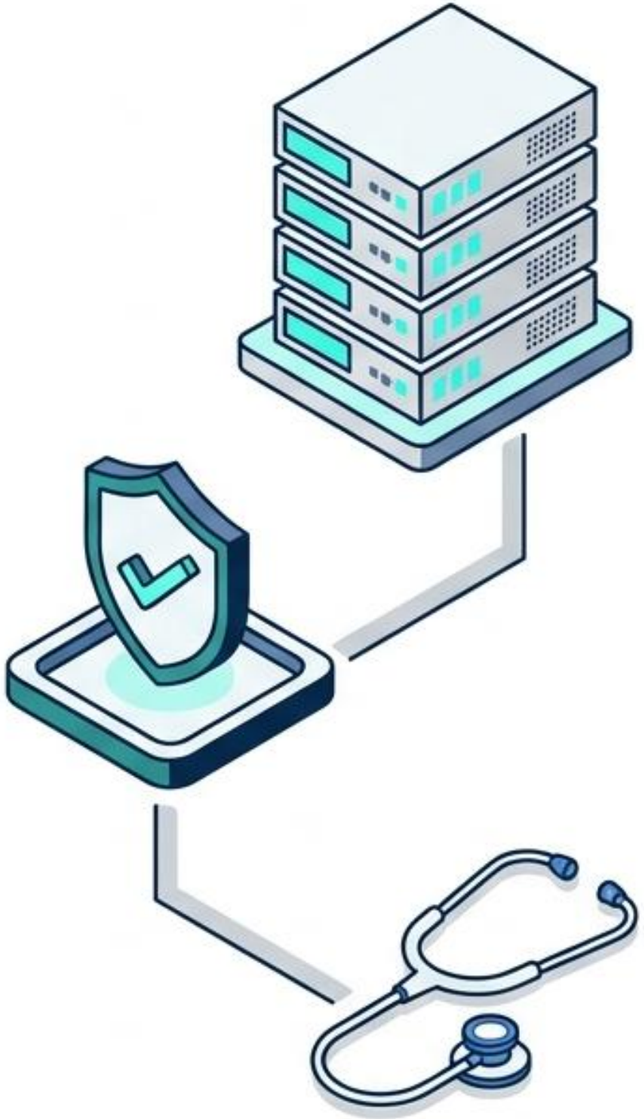

De la Prueba de Concepto (PoC) a la IA Soberana: Arquitectura, Retos Clínicos y Cumplimiento Normativo

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España · Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Resumen Ejecutivo: El Dilema de la IA en Salud

La Promesa Clínica

- Revolución en la interacción con datos de pacientes.
- Asistentes tipo ChatGPT prometen resumir historiales complejos.
- Redacción ágil de informes para devolver tiempo al médico en atención directa.

→

El Freno Normativo

- El envío de Información de Salud Protegida (PHI) a nubes públicas es un riesgo crítico.
- Choque frontal con normativas estrictas de privacidad (GDPR en Europa, HIPAA en EE.UU.).
- Miedo legítimo a la exposición de datos sensibles en cajas negras comerciales.

→

La Solución Soberana

- Infraestructuras de IA In-House mediante Docker Model Runner (DMR).
- Procesamiento 100% aislado: los datos nunca abandonan la red del hospital.
- Democratización del acceso a IA avanzada manteniendo el estricto cumplimiento ético y legal.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España · Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Arquitectura Conceptual de la Prueba de Concepto (PoC)

Capa Superior: El Usuario Clínico (Navegador Web)

- Interacción fluida sin necesidad de conocimientos técnicos.
- Experiencia democratizada para personal médico y de enfermería.

Red Local del Hospital - Aislamiento Total

Capa Media: La Interfaz (Open WebUI)

- Contenedor auto-hospedado (Puerto 3000).
- Provee la experiencia gráfica estilo ChatGPT a la red local.

Capa Base: El Motor Local (Docker Model Runner - DMR)

- Motor de inferencia nativo (Puerto 12434).
- Ejecuta modelos como ai/smollm2 o medgemma de forma eficiente.
- Compatible con APIs estándar (OpenAI/Ollama).

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Diagnóstico: ¿Por qué DMR frente a soluciones Cloud?

	Cloud LLMs	DMR (IA Local Soberana)
Privacidad de Datos (PHI)	[X] Alta transferencia de datos, riesgo de brechas en terceros.	✅ Procesamiento In-house 100% aislado. Cumplimiento garantizado de GDPR/HIPAA.
Control y Auditoría	[X] Modelos de caja negra que cambian sin previo aviso.	✅ Versionado exacto (ej. medgemma-1.5-4b-it-GGUF), inmutable y trazable.
Latencia y Disponibilidad	[X] Dependiente de la red externa; vulnerable a caídas de internet.	✅ Inferencia local ultrarrápida, resiliente y de acceso inmediato.
Modelo de Costes	[X] Pago recurrente e impredecible por token a escala.	✅ Uso de infraestructura existente (CAPEX vs OPEX).

CESTE Centro Universitario · TECH FAB LAB · IAF Instituto Aragonés de Fomento · Gobierno de España Ministerio para la Transformación Digital y de la Función Pública · Plan de Recuperación, Transformación y Resiliencia · Gobierno de Aragon · Financiado por la Unión Europea NextGenerationEU

Fase 1 - Despliegue de Base (CLI y Rendimiento)

Consola Base (Docker CLI)

```
Ejecución interactiva:
$ docker model run ai/smollm2

Auditoría de modelos instalados:
$ docker model list

Depuración (Debugging):
$ docker model logs <nombre_modelo>

Eliminación:
$ docker model rm <nombre_modelo>
```

El Poder del Background en Urgencias

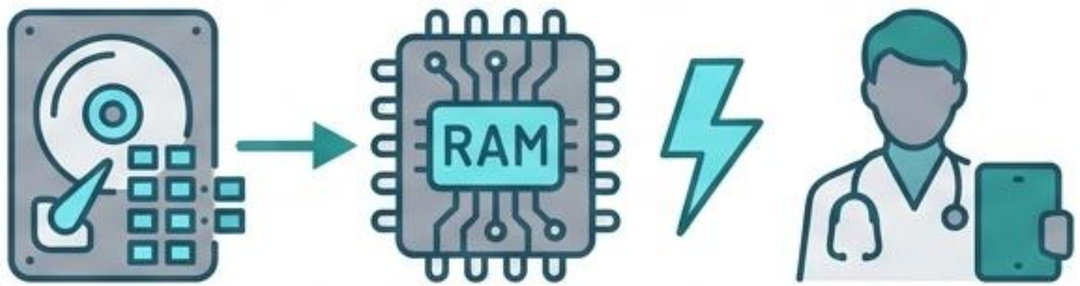

El comando crítico:
`$ docker model run --detach ai/smollm2`

El Beneficio Técnico: El modelo se carga y se mantiene vivo en la memoria RAM persistente.

El Beneficio Clínico: En medicina, el tiempo es oro. Al evitar la penalización de carga desde el disco duro en cada nueva petición, el médico obtiene una respuesta instantánea al consultar una historia clínica o protocolo de urgencias.

Fase 2 - Integración Gráfica (Docker Compose)

```yaml
docker-compose.yml

services:
  open-webui:
    image: ghcr.io/open-webui/open-webui:main
    ports:
      - 3000:8080
    environment:
      WEBUI_AUTH=false
      OLLAMA_BASE_URL=http://host.docker.internal:12434
  ports:
    - open-webui
```

La Interfaz: Contenedor gráfico principal. Despliegue ultrarrápido visible y expuesto a la red en el puerto 3000.

Alerta de Seguridad: Acelera esta PoC al eliminar el login. Riesgo crítico en producción al perder trazabilidad de qué facultativo accede a qué datos.

El Enrutador Vital: Permite que la interfaz web se comunique transparentemente con el motor DMR subyacente alojado en el host.

`$ docker-compose up -d` para levantar el ecosistema.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Check-point: Auditoría de Conocimiento y Principios de Diseño

Lógica Técnica

Principio 1: DMR actúa como el motor nativo de IA local, no como una pasarela o conexión a la nube. Todo el cómputo ocurre en el nodo.

Principio 2: Ejecutar modelos con el flag **--detach** es un requisito de rendimiento, rendimiento, no una opción, para eliminar la fricción temporal en el flujo de trabajo clínico.

Cumplimiento Ético

Principio 3: Esta arquitectura minimiza el riesgo de exposición de PHI, facilitando directamente el cumplimiento de normativas como GDPR y HIPAA.

Principio 4: La variable WEBUI_AUTH=false es exclusiva para esta PoC. Desplegarla en un hospital real eliminaría la auditoría de acceso, violando la trazabilidad clínica.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España · Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

The Clinical Blueprint

La Dinámica de Trabajo: Retos por Niveles

La adopción exitosa de IA médica requiere una alineación perfecta entre el diseño de flujos de valor y la precisión técnica. Hemos diseñado dos vías de trabajo en paralelo para este ejercicio.

Camino A

El Estratega: C-Level y Directores Médicos

- **Foco:** Casos de Uso, Gestión del Cambio y Flujos de Trabajo (Workflows) Hospitalarios.
- **Misión:** Diseñar el encaje operativo de la IA en la práctica médica diaria sin disrupción.

Camino B

El Builder: Desarrolladores e Ingenieros

- **Foco:** Ajuste de Modelos (Tuning), Inyección de Conocimiento (RAG) y Mitigación de Alucinaciones.
- **Misión:** Configurar la precisión determinista del motor y conectar el conocimiento institucional.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España · Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Reto Estratega: Diseñando el Copiloto Clínico

Bloque 1: Casos de Uso de Bajo Riesgo (Dónde Empezar)

¿En qué departamentos el impacto inicial será alto pero el riesgo clínico bajo?

Ejemplos a debatir: **Triaje pre-clínico**, **resúmenes automáticos de altas hospitalarias**, asistencia en **facturación** (codificación CIE-10), traducción de informes técnicos a lenguaje para el paciente.

Bloque 2: Barreras de Adopción Operativa (Gestión del Cambio)

¿Cómo superaremos el escepticismo natural del personal sanitario?

Soluciones a debatir: Creación de comités internos de validación de IA, programas de formación continua, protocolos de uso aceptable.

Bloque 3: Mapeo del Flujo de Trabajo (El Momento de la Verdad)

¿En qué momento exacto del Patient Journey interactúa el facultativo con la IA?

¿Tiene el paciente visibilidad de esta interacción, o es una herramienta puramente de back-office?

CESTE Centro Universitario · TECH FAB LAB · IAF Instituto Aragonés de Fomento · Gobierno de España Ministerio para la Transformación Digital y de la Función Pública · Plan de Recuperación, Transformación y Resiliencia · Gobierno de Aragón · Financiado por la Unión Europea NextGenerationEU

Reto Builder (Fase 1): Ajuste de Precisión (Tuning)

Contexto: En medicina, la alucinación (inventar datos) no es un error de software, es un riesgo vital. Debemos eliminar la creatividad de la IA.

Misión 1: Reducción de Aleatoriedad

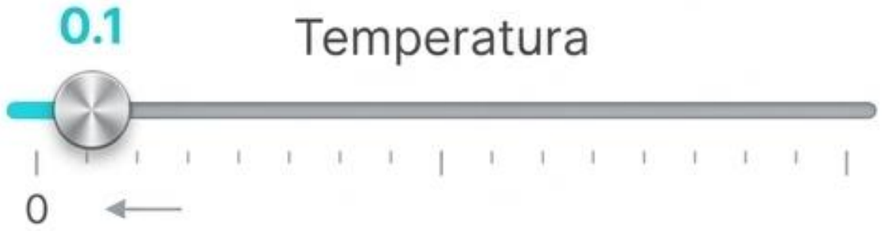

Creative Brain

Logical Brain

Ajustar Temperatura a 0.1 fuerza respuestas deterministas y basadas en hechos.

Misión 2: El System Prompt Clínico Estricto

```
Instrucción de Base:

Eres un asistente médico experto.
Responde única y exclusivamente
basándote en evidencia comprobada.
Si no estás 100% seguro, indica
explícitamente: "Como IA, carezco
de evidencia para responder
esto".
```

Reto Builder (Fase 2): El Camino hacia RAG

Contexto: El modelo base conoce la medicina general, pero desconoce los protocolos específicos de nuestro hospital.

1. Carga de Conocimiento

Utilizar Workspace en Open WebUI para subir un protocolo interno en PDF o TXT.

2. Inyección de Contexto

Usar el comando # en el chat para referenciar y anclar el documento.

DMR / Medgemma

3. Inferencia Restringida

El modelo razona exclusivamente sobre el texto aportado como contexto estricto.

4. Resultado

Respuestas precisas y altamente contextualizadas a la realidad del hospital.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España · Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Roadmap de Producción: Identificando Limitaciones

El Realismo del Consultor: La arquitectura actual demuestra que la IA clínica soberana es factible y útil. Sin embargo, una PoC exitosa a menudo engaña a las organizaciones haciéndoles creer que están listas para producción.

Antes de permitir el acceso masivo en el hospital, debemos resolver estas tres brechas arquitectónicas y procedimentales ineludibles.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España · Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU

Brechas de Infraestructura: Seguridad y Escalabilidad

Brecha 1: Identidad y Trazabilidad

Limitación PoC:
Acceso anónimo (WEBUI_AUTH=false); no existe un registro auditable de quién sube datos PHI.

Solución Empresarial:
Integración vía OAuth2 con el Active Directory / LDAP del hospital.
Implementación de un Audit Log inmutable para cumplimiento riguroso de Compliance.

Brecha 2: Escalabilidad de Nodos

Limitación PoC:
El modelo corre en una única máquina. Colapsaría si 150 médicos de guardia piden un resumen simultáneamente.

Solución Empresarial:
Transición de docker-compose simple a orquestadores robustos (Kubernetes, Docker Swarm) y balanceadores de carga para escalar horizontalmente las instancias DMR.

Brecha 3: Validación de Precisión Médica

La Limitación Base: Incluso utilizando LLMs especializados, los modelos siguen siendo sistemas estadísticos probabilísticos susceptibles a sesgos.

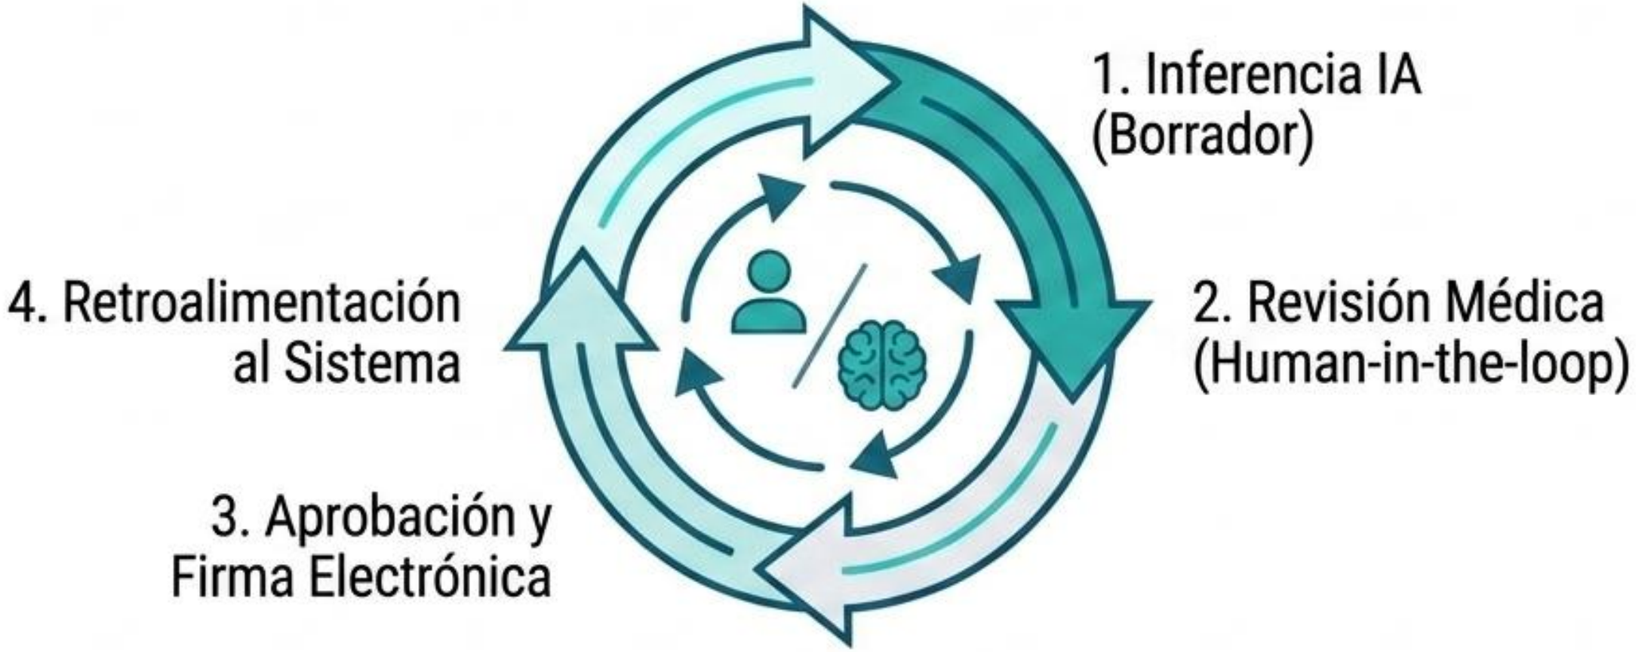

Solución Empresarial (Procesos de Negocio):

- Diseñar el flujo para que la IA únicamente redacte borradores. El médico especialista siempre valida y corrige.
- Autonomía Restringida: La IA nunca toma decisiones de triaje final de forma autónoma.
- Pipelines de Evaluación: Establecer comités clínicos que auditen periódicamente muestras de respuestas antes del lanzamiento.

Siguientes Pasos: Ejecución del Ejercicio

Despliegue Técnico (Builders)

- Levantar el entorno docker-compose.
- Instalar los modelos interactivos smollm2 y medgemma mediante DMR.

Alineación Clínica (Estrategas)

- Ejecutar los retos de Tuning (Temperatura y RAG).
- Debatir los casos de uso internos de bajo riesgo aplicables a sus respectivos departamentos.

Planificación Estratégica (Liderazgo)

- Definir el roadmap interno para superar barreras de autenticación (LDAP).
- Diseñar la escalabilidad hacia un entorno de producción regulado.

CESTE Centro Universitario
TECH FAB LAB
IAF Instituto Aragonés de Fomento
Gobierno de España Ministerio para la Transformación Digital y de la Función Pública
Plan de Recuperación, Transformación y Resiliencia
Gobierno de Aragon
Financiado por la Unión Europea NextGenerationEU